




Predicción de Precios Dinámicos - PropTech (nombre provisional)

Autor: **Ricardo Fernández**

Índice de la Presentación

01

El Problema y la Oportunidad

02

Hipótesis y Objetivos del Proyecto

03

Datos: Las 3 Dimensiones del Problema

04

Ingeniería de Datos (Hito 1)

05

Modelado y Benchmark (Hito 2)

06

Despliegue en Producción (Hito 3)

07

Fine-Tuning Internacional

08

Conclusiones, KPIs y Trabajo Futuro



BLOQUE 1 — EL PROBLEMA Y LA OPORTUNIDAD

El alquiler vacacional pierde dinero por fijar mal sus precios

Overpricing

Pisos vacíos por tarifas infladas por encima del mercado.

Underpricing

El anfitrión baja el precio a última hora y regala noches.

El precio medio en Madrid varía $\pm 30\%$ entre semanas del mismo mes. La mayoría de anfitriones fija tarifas por intuición, sin datos.

El precio "justo" depende de más de 50 variables que cambian constantemente



Un modelo de **ML supervisado** aprende la función que relaciona estas variables con los precios históricos.

Soluciones existentes: Smart Pricing de Airbnb (caja negra no auditable), Spaces de HF (incompletos, sin barrio), soluciones hoteleras (cerradas). Mi propuesta une las tres dimensiones en un único pipeline auditable.

Hipótesis central y objetivos del PFC

«Es posible predecir la tarifa óptima con un error medio absoluto **inferior a 35 €**, integrando infraestructura, reputación y demanda, preservando las firmas de cardinalidad alta como el barrio.»

H1 — Integración multimodelo

Mejora la predicción frente a usar solo datos estructurados.

H2 — Generalización geográfica

Portable a otros mercados mediante fine-tuning (Madrid → NYC).

H3 — Desplegable en producción

Coste de inferencia despreciable en HF Spaces.



Objetivos técnicos y académicos

Objetivos técnicos:

- Construir una arquitectura federada que ingiera 3 fuentes heterogéneas (RDS, Mongo, Kafka).
- Implementar un pipeline de preprocesamiento robusto frente a outliers y datos faltantes.
- Entrenar y validar ≥ 3 modelos de ML supervisado con búsqueda de hiperparámetros.
- Desplegar el modelo ganador como servicio web accesible públicamente.
- Validar la generalización geográfica con un experimento de Transfer Learning.

Objetivos académicos:

- Demostrar dominio del ciclo de vida completo de un proyecto de IA: datos $\rightarrow$ modelo $\rightarrow$ producción.
- Aplicar buenas prácticas de MLOps: reproducibilidad, versionado de artefactos, CI/CD.
- Generar un repositorio reproducible (random_state=42, requirements fijados).

Las 3 dimensiones del problema



Infraestructura física (RDS)

~ Listings públicos de Inside Airbnb.
Variables: price, accommodates, baños, barrios, entre otras.



Reputación digital (MongoDB Atlas)

~ Reseñas también de Inside Airbnb. Se procederá a crear una variable conteo review



Demanda en tiempo real (Kafka)

Simulador de clickstream con embudo de conversión realista. Feature:
total_clicks_acumulados en ventana móvil de 15 min.

Inside Airbnb
Adding data to the debate

DataAboutSupportCommunityDonate!

Donate! If you support the mission of the project, or rely on the data for your work, please consider making a donation to help make this effort sustainable.

Get the Data

Quarterly data for the last year for each region is available for free download on this page.

NEW! We now have regional archive files for research on entire countries: Australia, Canada, France, Germany, Greece, Italy, The Netherlands, Portugal, Spain, Sweden, the United Kingdom and the United States.

If you don't see the data you are looking for, or would like to access additional archived data please make a data request.

This data is licensed under a Creative Commons Attribution 4.0 International License.

Data Resources

- Explore or Get the data
- Read Data Policies
- Make a Data Request
- Read Data Assumptions
- View the Data Dictionary
- Join the Data Community

Data Downloads

Albany, New York, United States

15 February, 2026 [Explore](#)

Country/City	File Name	Description
Albany	listings.csv.gz	Detailed Listings data
Albany	calendar.csv.gz	Detailed Calendar Data
Albany	reviews.csv.gz	Detailed Review Data

Auditoría de calidad - Nulos variable objetivo

- **42,15 %** de nulos en price → filtrado estricto

INICIANDO AUDITORÍA OPERACIONAL DE ARCHIVOS CRUDOS (RAW)...


Ruta de inspección: <C:\Users\Ric\Desktop\PFC\datasets\raw>

Región / Subcarpeta	Registros Totales	Nulos en Price	% de Nulos
Barcelona	18,177	18,177	100.00%
Global	61,106	25,757	42.15%
Madrid	25,000	6,047	24.19%
Málaga	9,714	899	9.25%
Sevilla	8,215	634	7.72%
RESUMEN AGREGADO (RAW)	122,212	51,514	42.15%

Como se puede ver, nuestros datasets presentaban de base valores nulos sobre todo en el dataset de Barcelona, siendo estos completamente nulos, viendo el dataset manualmente podemos ver cosas como la siguiente:


```
..., "Pack 'n play/Travel crib""]",,1,1125,1,4,...  
      ↑↑
```


Auditoría de calidad - Distribución precios




Auditoría de calidad

5. Datos Documentales: Histórico de Reseñas (MongoDB) vs Precio



6. Señales Dinámicas: Clickstream en Tiempo Real (Kafka) vs Precio



Reducción de variables predictoras

Filtro de variables completado con éxito:

- > Columnas eliminadas por redundancia, ruido o leakage: 76
- > Estructura actual del DataFrame de trabajo: 61,106 filas y 12 columnas.

Columnas definitivas para el modelo:

01. Variable: listing_id	Tipo de dato: int64
02. Variable: neighbourhood_cleansed	Tipo de dato: str
03. Variable: room_type	Tipo de dato: str
04. Variable: accommodates	Tipo de dato: int64
05. Variable: bedrooms	Tipo de dato: float64
06. Variable: beds	Tipo de dato: float64
07. Variable: bathrooms	Tipo de dato: float64
08. Variable: minimum_nights	Tipo de dato: int64
09. Variable: maximum_nights	Tipo de dato: int64
10. Variable: total_reviews_historicas	Tipo de dato: int64
11. Variable: total_clicks_acumulados	Tipo de dato: int64
12. Variable: price	Tipo de dato: float64

Reducciones de datos interesantes

DIAGNÓSTICO DE TECHOS TÉCNICOS POR CAPACIDAD DE HUÉSPEDES:

Capacidad (accommodates)	Q1	Q3	IQR	Techo (Q3+3*IQR)	Excluidos
Huéspedes: 1	\$29.0	\$52.0	\$23.0	\$121.0	130
Huéspedes: 2	\$61.0	\$120.0	\$59.0	\$297.0	320
Huéspedes: 3	\$80.0	\$135.0	\$55.0	\$300.0	83
Huéspedes: 4	\$95.0	\$168.0	\$73.0	\$387.0	404
Huéspedes: 5	\$106.0	\$186.0	\$80.0	\$426.0	72
Huéspedes: 6	\$129.0	\$236.0	\$107.0	\$557.0	99
Huéspedes: 7	\$137.0	\$263.0	\$126.0	\$641.0	15
Huéspedes: 8	\$170.0	\$336.0	\$166.0	\$834.0	17
Huéspedes: 9	\$184.5	\$433.0	\$248.5	\$1178.5	5
Huéspedes: 10	\$215.2	\$506.2	\$291.0	\$1379.2	9
Huéspedes: 11	\$225.0	\$553.0	\$328.0	\$1537.0	0
Huéspedes: 12	\$294.0	\$555.0	\$261.0	\$1338.0	5
Huéspedes: 13	\$332.0	\$662.0	\$330.0	\$1652.0	1
Huéspedes: 14	\$285.5	\$787.5	\$502.0	\$2293.5	1
Huéspedes: 15	\$319.0	\$628.8	\$309.8	\$1558.0	0
Huéspedes: 16	\$314.2	\$788.0	\$473.8	\$2209.2	2

✓ FILTRADO POR CAPACIDAD DE NEGOCIO COMPLETADO:

- > Total de registros excluidos globalmente por desproporción precio/capacidad: 1,163
- > Porcentaje de la muestra depurado: 3.290%
- > Dimensiones finales del DataFrame de mercado real: 34,186

Una terna de modelos para comparar

Para determinar el modelo de predicción óptimo, se evaluó un trío de algoritmos con características y enfoques distintos.



Random Forest Regressor

```
modelo_rf_opt = RandomForestRegressor(  
    n_estimators=250,  
    max_depth=15,  
    min_samples_split=5,  
    min_samples_leaf=2,  
    random_state=42,  
    n_jobs=-1  
)
```



XGBoost Regressor ★

```
modelo_xgb_opt = XGBRegressor(  
    n_estimators=350,  
    learning_rate=0.04,  
    max_depth=6,  
    subsample=0.8,  
    colsample_bytree=0.8,  
    random_state=42,  
    n_jobs=-1  
)
```



MLPRegressor (Deep Learning)

```
modelo_mlp_opt = MLPRegressor(  
    hidden_layer_sizes=(128, 64, 32),  
    activation='relu',  
    solver='adam',  
    alpha=0.001,  
    max_iter=700,  
    early_stopping=True,  
    validation_fraction=0.1,  
    random_state=42  
)
```

Resultados Preliminares: Una Comparativa de Modelos

Modelo	MAE_Test (€)	RMSE_Test (€)	R2_Test (%)
XGBoost Regressor	33.28	54.34	70.01
Random Forest Regressor	33.14	54.87	69.83
Red Neuronal (MLP)	35.99	56.31	65.09

Los resultados iniciales muestran que tanto **Random Forest** como **XGBoost Regressor** superan a la **Red Neuronal (MLP)** en las métricas de rendimiento clave. Ambos modelos basados en árboles alcanzan un error medio absoluto inferior a 35 € y una capacidad explicativa (R2) cercana al 70%, validando la hipótesis central del proyecto.

La vuelta definitiva - GridSearch

Para determinar el modelo de predicción óptimo, se evaluó un trío de algoritmos con características y enfoques distintos.



Random Forest Regressor

```
param_grid_rf = {  
    'n_estimators': [150, 250, 350],  
    'max_depth': [12, 15, 18],  
    'min_samples_split': [4, 6],  
    'min_samples_leaf': [2, 3]  
}
```



XGBoost Regressor ★


```
param_grid_xgb = {  
    'n_estimators': [300, 450, 600],  
    'learning_rate': [0.02, 0.04, 0.06],  
    'max_depth': [6, 7, 8],  
    'min_child_weight': [1, 3],  
    'reg_lambda': [1.0, 1.5]  
}
```



MLPRegressor (Deep Learning)

```
param_grid_mlp = {  
    'hidden_layer_sizes': [(128, 64, 32), (256, 128, 64)],  
    'activation': ['relu', 'tanh', 'identity'],  
    'solver': ['adam', 'sgd'],  
    'alpha': [0.001, 0.005],  
    'learning_rate_init': [0.001, 0.005]  
}
```

XGBoost gana por goleada



Métricas definitivas en test


Modelo	R²	MAE
Random Forest	64,2 %	41,87 €
XGBoost ★	71,38 %	32,24 €
MLP Regressor	67,9 %	36,50 €

Precio mediano real: **108,50 €**. Un MAE de 32 € equivale a
≈ 30 % del precio medio – resultado excelente.

El modelo es interpretable: ¿qué mira para fijar el precio?



El análisis de la importancia de las variables (Feature Importance) revela qué características son cruciales para que el modelo XGBoost determine el precio de un alquiler vacacional.

Variable



La **tipología de habitación** es, con diferencia, el factor más influyente, explicando un 81,61 % de la varianza total. Otros predictores físicos como el número de baños y la capacidad (accommodates) también son significativos. Curiosamente, la variable de **barrio** tiene una importancia relativamente baja (1,72 %), lo que sugiere que su impacto ya está en gran medida capturado por la colinealidad estructural con el tipo de estancia.

Representación del Modelo Obtenido: Evaluación Diagnóstica de Capacidad Predictiva en Test



Dashboard hugging face: una UI limpia para no técnicos

Para facilitar la interacción con el modelo predictivo, se ha desarrollado una interfaz de usuario intuitiva utilizando Gradio, diseñada para usuarios no técnicos.

- **Estructura del inmueble:** tipo de estancia (dropdown), barrio (textbox), dormitorios/baños/camas/capacidad (sliders 0–16).
- **Parámetros de mercado:** mínimo y máximo de noches (números).
- **Datos de demanda:** clics en tiempo real + total de reseñas (números).
- **Botón principal:** "🚀 **Calcular Precio Óptimo**".
- **Output:** franja verde con el precio sugerido en euros grandes.





BLOQUE 6 – DESPLIEGUE EN PRODUCCIÓN (HITO 3)

Del cuaderno al Space: pipeline de despliegue continuo



1. Empaquetar

Copia de artefactos a la carpeta `/app` para su inclusión en el contenedor.



2. Inyectar `app.py`

Generación del script principal `app.py` y `requirements.txt`.



3. `hf_hub.upload_folder`

Subida de los archivos necesarios al Space de Hugging Face.



4. HF compila contenedor

Hugging Face realiza automáticamente el Docker build y despliega la aplicación.



5. URL pública

Acceso a la aplicación del modelo a través de una URL pública: [https://\[nombre\].hf.space](https://[nombre].hf.space)

El Space no es solo UI: también es una API REST

Más allá de la interfaz de usuario interactiva, el Space de Hugging Face expone una potente API REST. Esto permite la integración programática del modelo de predicción de precios en otras aplicaciones, sistemas o flujos de trabajo automatizados, ampliando significativamente su utilidad.

```
from gradio_client import Client

client = Client("<USER_HF>/<NOME_REPOSITORIO>")
respuesta = client.predict(
    "Centro", "Entire home/apt", 4.0, 2.0, 2.0, 1.0,
    2.0, 30.0, 42.0, 150.0,
    api_name="/predict"
)
```


Inicializando el cliente de conexión remota...

Loaded as API: <https://ricardofg2000-pfc-dashboard.hf.space>

✅ Conexión establecida con éxito con la API en: <https://huggingface.co/spaces/ricardofg2000/pfc-dashboard>

🚀 Enviando petición de tarificación dinámica en orden estricto...

🔄 RESPUESTA RECIBIDA DESDE EL SERVIDOR CLOUD:

Tarifa Sugerida

102.33 €

Precio optimizado por noche (Alineación Secuencial Cloud)

¿El modelo de España funciona en Nueva York?

Al intentar aplicar directamente el modelo entrenado con datos de España a la ciudad de Nueva York, surge la pregunta crítica de su generalizabilidad y adaptabilidad.


- **Hipótesis H2:** El modelo es generalizable a otros mercados con un ajuste fino (fine-tuning).
- **Domain Shift:** Existe un cambio significativo en la distribución de los datos entre Madrid (€, barrios españoles, cultura del alquiler mediterránea) y Nueva York (\$, Manhattan vs Brooklyn, cultura anglosajona).
- **Dataset externo:** Para probar esta hipótesis, se utilizó el dataset `AB_NYC_2019.csv` de Kaggle (48.895 registros), descargado con `kagglehub`.
- **Riesgo:** Un modelo de España aplicado a NYC sin adaptación se comporta **peor que predecir la media** (resultando en un R^2 negativo).



El Fine-Tuning salva el Domain Shift

Métrica	Modelo base (España en NYC)	Fine-Tuned (NYC Especializado)	Impacto
MAE (Desviación Media)	91,01 \$	64,17 \$	Δ MAE = -26,84 \$ ✓
R² (Varianza Explicada)	-0,129	+0,146	Δ R² = +0,275 ✓

La comparación visual de las métricas clave muestra la mejora sustancial lograda con el enfoque de fine-tuning:





Indicadores clave de éxito (todos conseguidos)

El proyecto ha alcanzado y superado todos los objetivos definidos, demostrando la solidez y eficacia del modelo de predicción de precios dinámicos. A continuación, se presenta un resumen de los KPIS:

KPI	Valor objetivo	Valor conseguido	Estado
Modelos entrenados y auditados	≥ 3	3 (RF, XGB, MLP)	✓
R ² en Test del modelo maestro	$> 65 \%$	71,38 %	✓
MAE de producción	$< 40 \text{ €}$	32,24 €	✓
Experimentos de Transfer Learning	1	1 (España → NYC)	✓
Mejora Δ MAE por Fine-Tuning	$> 15 \$$	-26,84 \$	✓
Mejora Δ R ² por Fine-Tuning	$> 0,15$	+0,275	✓
Despliegue en producción	HF Space público	✓ activo	✓
Reproducibilidad total	random_state=42	✓ todos los componentes	✓
Tests de validación visual	Dispersión + residuos	✓ ambos	✓

Lo que aprendí en el proceso (más allá del código)



La Calidad de los Datos es Rey

Un modelo robusto se construye sobre cimientos sólidos. La dedicación a la limpieza, auditoría y preparación de los datos iniciales es fundamental para el éxito y la fiabilidad del modelo, evitando "garbage in, garbage out".



Interpretabilidad para la Confianza

Entender "por qué" un modelo toma ciertas decisiones es tan crucial como su precisión. La interpretabilidad (como SHAP) construye confianza, facilita la depuración y permite validar si el modelo aprende lógicas de negocio correctas.



La Importancia del Transfer Learning

La capacidad de adaptar un modelo previamente entrenado a nuevos dominios con un "fine-tuning" mínimo (como España → NYC) demuestra una eficiencia asombrosa y la escalabilidad del enfoque, superando el "domain shift".



MLOps: Del Cuaderno a la Realidad

Un modelo no genera valor hasta que está en producción y es accesible. La construcción de un pipeline de despliegue continuo (CI/CD) y una interfaz de usuario/API robusta son esenciales para llevar la inteligencia del modelo al usuario final.